

# Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI  
I TECHNIK INFORMACYJNYCH



Instytut Informatyki

Studia Podyplomowe  
Big Data - przetwarzanie i analiza dużych zbiorów danych

PRACA KOŃCOWA

Michał Kamiński

Wieloskalowa analiza danych z forum internetowego przy użyciu zasobów  
infrastruktury chmurowej AWS oraz technologii Spark

Warszawa, 2023

## STRESZCZENIE

W niniejszej pracy zaprezentowano przykładową infrastrukturę wykorzystującą zasoby chmury AWS (ang. *Amazon Web Services*) umożliwiającą analizę dużych zbiorów danych za pomocą klastów obliczeniowych przy użyciu serwisu AWS EMR (ang. *Elastic Map Reduce*). Zaprezentowano, jak przygotować przykładowe dane oraz dokonano wstępnej analizy danych pochodzących z repozytorium Stack Exchange przy użyciu technologii Spark, wykorzystując API w języku Python (**pySpark**)

Słowa kluczowe: **Big Data, Spark, AWS, EMR, S3**

---

## Large scale analysis of data from internet forum using cloud infrastructure resources

The thesis demonstrates the cloud infrastructure built using Amazon Web Services (AWS), that allows efficient analysis of large data sets (Big Data) using distributed computing system with example of AWS Elastic Map Reduce (EMR) service. As a demonstration of data preparation and initial analysis, python Spark API (**pySpark**) was used to analyze data from one of Stack Exchange forum.

Keywords: **Big Data, Spark, AWS, EMR, S3**

# Spis treści

<b>I</b>	<b>WSTĘP</b>	<b>5</b>
	Technologie big data . . . . .	6
	Formaty danych . . . . .	6
	Wykorzystanie zasobów chmurowych . . . . .	8
	Cel pracy . . . . .	8
<b>II</b>	<b>WYNIKI</b>	<b>9</b>
<b>1</b>	<b>Schemat infrastruktury rozwiązania</b>	<b>10</b>
1.1	Ekstrakcja danych surowych . . . . .	10
1.2	Przygotowanie danych wstępnych . . . . .	11
<b>2</b>	<b>Wstępna obróbka danych</b>	<b>12</b>
2.1	Konfiguracja aplikacji Spark . . . . .	12
2.2	Schematy danych . . . . .	12
2.2.1	Plik Users . . . . .	12
2.2.2	Plik Tags . . . . .	13
2.2.3	Plik Votes . . . . .	13
2.2.4	Plik Posts . . . . .	14
2.2.5	Plik Post Links . . . . .	15
2.2.6	Plik Post History . . . . .	15
2.2.7	Plik Badges . . . . .	16
2.3	Czyszczenie kolumn tekstowych . . . . .	16
<b>3</b>	<b>Analiza danych</b>	<b>19</b>
3.1	Analiza aktywności użytkowników na forum . . . . .	19
3.2	Dynamika oraz statystyki udzielanych odpowiedzi . . . . .	21
3.3	Retencja użytkowników . . . . .	23
3.4	Statystyki najwyżej oraz najniżej ocenianych pytań . . . . .	24
3.5	Analiza znaczników (tagów) . . . . .	27
3.6	Analiza tytułów postów . . . . .	29
<b>III</b>	<b>WNIOSKI I ZAKOŃCZENIE</b>	<b>31</b>
	Budowa infrastruktury . . . . .	32
	Analiza danych . . . . .	32
	<b>Załączniki</b>	<b>33</b>
<b>A</b>	<b>Budowanie infrastruktury chmurowej</b>	<b>34</b>
A.1	Polecenie AWS CLI dla usługi EMR . . . . .	34

A.2	Plik <code>install-my-jupyter-libraries.sh</code> . . . . .	34
A.3	Plik <code>emr-configurations.json</code> . . . . .	34
A.4	Polecenie AWS CLI dla usługi S3 . . . . .	35
<b>B</b>	<b>Definicje funkcji</b>	<b>36</b>
B.1	<code>tags_remove()</code> . . . . .	36
B.2	<code>regex_extract_all()</code> . . . . .	36
<b>C</b>	<b>Repozytorium kodu wykorzystanego w pracy</b>	<b>39</b>

**Cześć I**

**WSTĘP**

## Technologie big data

Ilość przetwarzanych danych cyfrowych na świecie rośnie w tempie logarytmicznym i obecnie podawana jest w dziesiątkach zettabajtów [8]. Wraz ze wzrostem ilości danych, niezbędne jest optymalizowanie bądź zwiększanie miejsca potrzebnego na ich przechowywanie oraz ulepszanie algorytmów pozwalających na dokonanie analiz w czasie umożliwiającym na szybkie wyciąganie wniosków i podejmowania stosownych akcji.

Znaczącym usprawnieniem procesu analitycznego opartego na dużych ilościach danych było opracowanie algorytmu **MapReduce** [9], wykorzystującego równoległe przetwarzanie zbiorów danych w klastrach komputerowych. Opiera się na stosowaniu dwóch “kroków”. Kroku **map**, odpowiadającego za wykonywanie zadań w węzłach roboczych (niezależnie od siebie) a następnie kroku **reduce**, który zbiera dane z węzłów roboczych i dokonuje kroku redukcji danych poprzez np. agregację.

Klastry komputerowe mogą być wykorzystywane nie tylko do obliczeń, ale również do przechowywania danych. Platformą, która wykorzystuje rozproszony system plików jest np. **Apache Hadoop** i system HDFS [3]. System HDFS daje możliwość na zwiększenie dostępności danych poprzez ich replikację. W przypadku niedostępności jednego z węzłów roboczych, dane są dostępne na pozostałych węzłach w postaci kopii. Dodatkowo poprzez odpowiednie partycjonowanie danych można usprawnić działania analityczne, które ograniczą wysyłanie danych po sieci klastra [12].

**Apache Hadoop** i **MapReduce** mają jednak swoje ograniczenia, z czego jednym z bardziej znaczących jest konieczność wczytywania danych z dysku dla każdego zadania. Jest to mało wydajne przy zadaniach wykonywanych w sposób iteracyjny jak np. trenowanie modeli statystycznych z wieloma hiperparametrami [18]. W pracy Zaharia i in. [18], zaprezentowano technologię **Spark** (obecnie **Apache Spark**), która obchodzi te ograniczenia poprzez wykorzystanie dużo szybszej pamięci RAM oraz wprowadzenie obiektów RDD (ang. *Resilient Distributed Datasets*) [17]. RDD są obiektami niemodyfikowalnymi (ang. *immutable*), rozproszonymi po klastrze i co najistotniejsze przechowywane w pamięci RAM. Dzięki temu obiekty RDD mogą być wykorzystywane wielokrotnie bez konieczności wykonywania operacji odczytu z dysku, który znacząco obniża tempo wykonywania obliczeń. Autorzy Zaharia i in. [18] szacują że **Apache Spark** jest około 10 razy szybszy niż **Apache Hadoop** w wykonywaniu iteracyjnym operacji związanych z uczeniem maszynowym.

## Formaty danych


W czasach sprzed tzw. ery Big Data, dane przechowywane były (oraz często dalej są) w relacyjnych bazach danych. W najprostszym założeniu (pomijając możliwości indeksowania oraz stosowania kluczy) dane przetrzymywane są w klasycznym schemacie, jedna obserwacja - jeden wiersz, jedna cecha - jedna kolumna (zobacz Tabela 1). W jaki sposób te dane są przechowywane na dysku obrazuje za to Rysunek 1. Przechowywanie informacji w ten sposób powoduje, że aby dokonać agregacji cechy znajdującej się w kolumnie o nazwie `kolumna1`, algorytm musi przeskanować wszystkie wiersze wczytując je do pamięci.

Rozwiązaniem, które usprawnia ten proces i jest wykorzystywane w rozwiązaniach typu Big Data jest przechowywanie danych w sposób kolumnowy, zaprezentowany na Rysunek 2. W tym przypadku, jeżeli naszym celem jest jedynie zagregowanie cechy `kolumna1`, to tylko dane z tej kolumny zostaną wczytane do pamięci, ponieważ algorytm wie, w którym miejscu na dysku znajdują się dane z tej kolumny. Przykładem formatów kolumnowych w systemie **Apache Hadoop** są **RCFile** oraz **ORC** a dodatkowo bardzo popularnym formatem jest format **Apache Parquet**.


Dodatkową zaletą formatów kolumnowych jest kompresja danych i zwiększenie szybkości wykonywania zapytań Tabela 2.

Tabela 1: Zobrazowanie tabeli rozrysowanej na Rysunek 1 oraz Rysunek 2

	kolumna1	kolumna2	kolumna3
wiersz1	A	B	C
wiersz2	D	E	F
wiersz3	G	H	I
wiersz4	J	K	L



Rysunek 1: Przykład wierszowego formatu danych. Kolejność wierszy przedstawia pozycję na dysku.



Rysunek 2: Przykład kolumnowego formatu danych. Kolejność wierszy przedstawia pozycję na dysku.

Tabela 2: Porównanie przykładowych danych przetrzymywanych w formacie CSV oraz Apache Parquet <sup>1</sup>

Format	Rozmiar danych	Czas wykonania zapytania (s)	Ilość wczytanych danych	Koszt (\$) <sup>2</sup>
CSV	1 TB	236	1.15 TB	5.75
Apache Parquet	130 GB	6.78	2.51 GB	0.01

<sup>1</sup><https://www.databricks.com/glossary/what-is-parquet>

<sup>2</sup>Szacunkowe koszty przechowywania oraz analizy w serwisie chmurze AWS

## Wykorzystanie zasobów chmurowych

W obecnych czasach, zapotrzebowanie na możliwość szybkiej analizy dużej ilości danych staje się wartością kluczową w zyskiwaniu przewagi biznesowej nad konkurencją [16]. Modele biznesowe opierające się na własnej infrastrukturze bądź własnym centrum analizy danych, wymagają ciągłego wsparcia i utrzymywania, niezależnie czy w danym momencie te zasoby są wykorzystywane czy też nie. Dodatkowo, w celu zwiększenia mocy analitycznych, często niezbędny jest zakup nowych maszyn, procesorów czy dysków, co znacząco wydłuża czas do otrzymywania wyników.

Rozwiązaniem na te problemy może być wykorzystanie zasobów chmurowych. Jednym z wiodących dostawców takich usług są Amazon Web Services (AWS), Google Cloud Platform (GCP) czy też Microsoft Azure, ale rynek ciągle rośnie i na popularności zyskują kolejni dostawcy [10]. Dzięki wykorzystywaniu zasobów chmurowych użytkownicy są w stanie dynamicznie zwiększać lub zmniejszać ilość zasobów, z których korzystają. Mogą to robić w sposób manualny, lub w momencie gdy zapotrzebowanie wzrasta, skorzystać z usługi automatycznego skalowania. Użycie takiego podejścia ma uzasadnione zastosowanie w momencie gdy pewne analizy wykonywane są w większych odstępach czasu, np. co miesiąc (np. na potrzeby miesięcznych podsumowań) lub w przypadku sklepów internetowych, gdy ruch na stronach okresowo wzrasta kilkukrotnie w stosunku do przeciętnego obciążenia sieci (np. w okresach świąt Bożego Narodzenia czy tzw. Czarne Piątku - ang. *Black Friday*).

W rozwiązaniach chmurowych użytkownik ma do wyboru czy tworzy własną infrastrukturę i odpowiada za jej utrzymywanie oraz odpowiednie aktualizacje (imituje w ten sposób posiadanie własnych zasobów, np. usługa AWS EC2 [1]) czy też korzysta z usług typu **serverless**, gdzie korzysta z gotowej usługi i płaci jedynie za czas jej pracy np. usługi AWS Lambda [7] czy AWS Rekognition [2]. Korzystanie z usług **serverless** odbywa się jednak kosztem braku możliwości wpływu na sposób działania aplikacji, którą w części przypadków musi potraktować jako rozwiązanie typu **black-box**. Przykładem może być wspomniana usługa AWS Rekognition, która jest usługą z dziedziny uczenia maszynowego do analizy plików wideo oraz audio. Użytkownik nie wie jakie modele statystyczne odpowiadają za analizę danych oraz wynik końcowy.

## Cel pracy

Celem niniejszej pracy jest utworzenie infrastruktury w chmurze obliczeniowej AWS pozwalające na wielkoskalową analizy danych w systemie rozproszonym przy użyciu technologii **Spark**.

Do stworzenia przykładowego projektu wykorzystano dane ze strony Stack Exchange [13] zawierającej zestawy danych pochodzące z forów społecznościowych. Analizę ograniczono do danych pochodzących z forum o nazwie *Beer, Wine and Spirits* [14]

Wyniki niniejszej pracy mogą posłużyć jako podstawa dla innych projektów, chcących rozszerzać wiedzę o zachowaniach użytkowników oraz poruszanej tematyki na różnych forach internetowych.

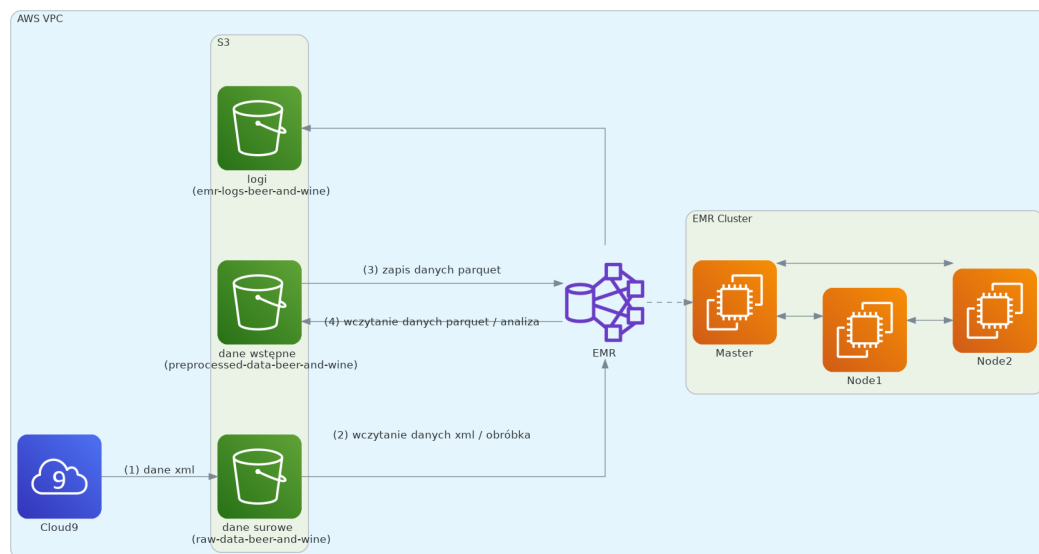


**Cześć II**

**WYNIKI**

# 1 Schemat infrastruktury rozwiązania

W celu rozwiązania postawionego problemu analitycznego stworzono infrastrukturę wyłącznie w obrębie chmury AWS, której ogólny schemat przedstawiono na Rysunek 1.1



Rysunek 1.1: Schemat infrastruktury rozwiązania w chmurze AWS

## 1.1 Ekstrakcja danych surowych

Do etapu ekstrakcji danych wykorzystano usługę Cloud9, która zapewnia dostęp do terminala maszyny wirtualnej z systemem linux (platforma Amazon Linux 2, typ instancji t2.micro). Z użyciem tej usługi dane zostały pobrane ze źródła w binarnym formacie 7z a następnie pliki zostały wyekstrahowane w formacie xml przy pomocy programu p7zip. Dane w formacie xml zostały następnie skopiowane do serwisu S3, gdzie utworzono koszyk danych (ang. *bucket*) o nazwie **raw-data-beer-and-wine**, którego przeznaczeniem jest przetwarzanie danych nieprzetworzonych.

Powyższe operacje zostały wykonane przy użyciu poniższych poleceń:

```
# instalacja programu p7zip
sudo yum install p7zip.x86_64

# pobranie danych
wget https://archive.org/download/stackexchange/beer.stackexchange.com.7z

# ekstrakcja danych do folderu raw-data
7za e beer.stackexchange.com.7z -oraw-data

# zapis danych do koszyka S3 przy użyciu programu `AWS CLI`
aws s3 cp $(pwd)/raw-data s3://raw-data-beer-and-wine/ --recursive --include "*.xml"
```

## 1.2 Przygotowanie danych wstępnych

W celu przygotowania danych do analizy, dane surowe zostały wstępnie przetworzone oraz zapisane w formacie **parquet** w koszyku danych **preprocessed-data-beer-and-wine**, co pozwoliło na wydajniejsze wczytywanie danych podczas uruchomień programu. Podczas etapu wstępnego przetwarzania danych, oprócz zmiany formatu plików, zdefiniowane zostały także schematy danych, które zapewnią, że kolumny wczytanych danych będą posiadały odpowiednie typy oraz, że krytyczne dane nie będą zawierały pustych wartości (Sekcja 2.2). Dodatkowo kolumny z wartościami tekstowymi, niesłownikowanymi zostały oczyszczone z tagów **html** oraz poddane standardowej procedurze oczyszczania tekstu (Sekcja 2.3).

Powyższe czynności zostały wykonane w notatniku typu **Jupyter** (ang. *Jupyter Notebook*) w serwisie **AWS EMR**. Stworzono klaster **EMR** (wersja 6.8.0) z instalacją **Hadoop 3.2.1**, **Jupyter Hub 1.4.1** oraz **Spark 3.3.0**. Klaster składał się z 1 instancji typu *master* oraz 2 instancji typu *core*, każda typu **m4.xlarge**. W celu ograniczenia kosztów jako opcję zakupu wybrano typ **spot** z limitem maksymalnym ceny odpowiadającej typowi **on-demand**. Wielkość dysków **EBS** stworzonych instancji wynosiła 32 GiB dla każdej instancji w klastrze.

Dostęp do **Jupyter Hub** w utworzonym klastrze jest możliwy poprzez połączenie przez przeglądarkę z środowiskiem graficznym **Jupyter Hub** wykorzystując publiczny adres DNS instancji *master* i port 9443. Dodatkowo w celu ułatwienia dostępu do **Jupyter Notebook**ów, utworzony klaster został skonfigurowany na automatyczne ich zapisywanie w dedykowanym koszyku danych w serwisie **S3** (patrz Sekcja A.3)

Polecenia programu **AWS CLI** odpowiadające za utworzenie klastra, wraz z niezbędnymi dodatkowymi plikami znajdują się w Załącznik A. Wszystkie serwisy **AWS** na potrzeby tego projektu zostały utworzone w sposób programatyczny przy użyciu programu **AWS CLI** (poza **Cloud9**, który został utworzony z poziomu konsoli zarządzającej).

## 2 Wstępna obróbka danych

### 2.1 Konfiguracja aplikacji Spark

W celu przygotowania danych do analizy zostały one wstępnie przetworzone. Pierwszym etapem wstępnego przetwarzania jest wczytanie danych do środowiska analitycznego. Dane surowe, przechowywane w koszyku `raw-data-beer-and-wine` znajdowały się w mało przyjaznym dla analiz formacie `xml`. Wczytanie tego typu danych wymagało załadowania dodatkowego pakietu `jar` o nazwie `spark-xml_2.12:0.15.0` pobranego z repozytorium `maven`.

W serwisie EMR można dodać tego typu pakiety wykorzystując specjalne polecenia typu `Sparkmagic` rozpoczynające się od znaków `%%`. W tym przypadku użyto `%%configure`:

```
%%configure -f
{
  "conf": {
    "spark.jars.packages": "com.databricks:spark-xml_2.12:0.15.0"
  }
}
```

### 2.2 Schematy danych

W celu zapewnienia wczytania danych o oczekiwanych typach oraz zapewnieniu że nie ma tam danych brakujących utworzono schematy danych, wykorzystywane w kroku wczytywania z plików `xml`. Poniżej przedstawiono schematy dla każdego z przetwarzanych plików oraz przykładowe wiersze.

#### 2.2.1 Plik Users

```
users_schema = StructType([
    StructField('_AboutMe', StringType(), True),
    StructField('_AccountId', IntegerType(), True),
    StructField('_CreationDate', TimestampType(), True),
    StructField("_DisplayName", StringType(), True),
    StructField("_DownVotes", IntegerType(), True),
    StructField("_Id", IntegerType(), True),
    StructField("_LastAccessDate", TimestampType()),
    StructField("_Location", StringType(), True),
    StructField("_ProfileImageUrl", StringType(), True),
    StructField("_Reputation", IntegerType(), True),
    StructField("_UpVotes", IntegerType(), True),
    StructField("_Views", IntegerType(), True),
    StructField("_WebsiteUrl", StringType(), True)
])
```

```

-RECORD 0-----
|_AboutMe      | <p>Hi, I'm not really a person.</p>\n\n<p>I'm a backgroun...
|_AccountId    | -1
|_CreationDate | 2014-01-21 17:45:53.587
|_DisplayName   | Community
|_DownVotes    | 478
|_Id           | -1
|_LastAccessDate | 2014-01-21 17:45:53.587
|_Location     | on the server farm
|_ProfileImageUrl | null
|_Reputation   | 1
|_UpVotes      | 2
|_Views        | 5
|_WebsiteUrl   | http://meta.stackexchange.com/
only showing top 1 row

```

## 2.2.2 Plik Tags

```

tags_schema = StructType([
    StructField('_Count', IntegerType(), True),
    StructField('_ExcerptPostId', IntegerType(), True),
    StructField('_Id', IntegerType(), True),
    StructField("_TagName", StringType(), True),
    StructField("_WikiPostId", IntegerType(), True)
])

```

```

+-----+-----+-----+-----+-----+
|_Count|_ExcerptPostId|_Id|_TagName|_WikiPostId|
+-----+-----+-----+-----+
| 17| 5062| 1| hops| 5061|
| 85| 7872| 2| history| 7871|
| 69| 4880| 4| brewing| 4879|
| 37| 5109| 5| serving| 5108|
| 31| 304| 6| temperature| 303|
+-----+-----+-----+-----+
only showing top 5 rows

```

## 2.2.3 Plik Votes

```

votes_schema = StructType([
    StructField('_BountyAmount', IntegerType(), True),
    StructField('_CreationDate', TimestampType(), True),
    StructField('_Id', IntegerType(), True),
    StructField("_PostId", StringType(), True),
    StructField("_UserId", IntegerType(), True),
    StructField("_VoteTypeId", IntegerType(), True)
])

```

```

+-----+-----+-----+-----+-----+
|_BountyAmount|_CreationDate|_Id|_PostId|_UserId|_VoteTypeId|
+-----+-----+-----+-----+-----+

```

	null	2014-01-21 00:00:00	1	1	null	2
	null	2014-01-21 00:00:00	2	1	null	2
	null	2014-01-21 00:00:00	3	4	null	2
	null	2014-01-21 00:00:00	4	1	null	2
	null	2014-01-21 00:00:00	5	4	null	2

+-----+-----+-----+-----+-----+-----+

only showing top 5 rows

## 2.2.4 Plik Posts

```
posts_schema = StructType([
    StructField('_AcceptedAnswerId', IntegerType(), True),
    StructField('_AnswerCount', IntegerType(), True),
    StructField('_Body', StringType(), True),
    StructField("_ClosedDate", TimestampType(), True),
    StructField("_CommentCount", IntegerType(), True),
    StructField("_CommunityOwnedDate", TimestampType(), True),
    StructField("_ContentLicense", StringType(), True),
    StructField("_CreationDate", TimestampType(), True),
    StructField("_FavoriteCount", IntegerType(), True),
    StructField("_Id", IntegerType(), True),
    StructField("_LastActivityDate", TimestampType(), True),
    StructField("_LastEditDate", TimestampType(), True),
    StructField("_LastEditorDisplayName", StringType(), True),
    StructField("_LastEditorUserId", IntegerType(), True),
    StructField("_OwnerDisplayName", StringType(), True),
    StructField("_OwnerUserId", IntegerType(), True),
    StructField("_ParentId", IntegerType(), True),
    StructField("_PostTypeId", IntegerType(), True),
    StructField("_Score", IntegerType(), True),
    StructField("_Tags", StringType(), True),
    StructField("_Title", StringType(), True),
    StructField("_ViewCount", IntegerType(), True),
])
```

```
--RECORD 0-----
_AcceptedAnswerId      | 4
_AnswerCount           | 1
_Body                  | <p>I was offered a beer the other day that was reportedly...
_ClosedDate            | null
_CommentCount          | 0
_CommunityOwnedDate    | null
_ContentLicense        | CC BY-SA 3.0
_CreationDate          | 2014-01-21 20:26:05.383
_FavoriteCount         | null
_Id                    | 1
_LastActivityDate      | 2014-01-21 22:04:34.977
_LastEditDate          | 2014-01-21 22:04:34.977
_LastEditorDisplayName | null
_LastEditorUserId      | 8
_OwnerDisplayName      | null
_OwnerUserId           | 7
_ParentId              | null
_PostTypeId            | 1
```

```

_Score          | 21
_Tags           | <hops>
_Title          | What is a citra hop, and how does it differ from other hops?
_ViewCount      | 2434
only showing top 1 row

```

## 2.2.5 Plik Post Links

```

links_schema = StructType([
    StructField("_CreationDate", TimestampType()),
    StructField("_Id", IntegerType()),
    StructField("_LinkTypeId", IntegerType()),
    StructField("_PostId", IntegerType()),
    StructField("_RelatedPostId", IntegerType())
])

```

```

+-----+-----+-----+-----+-----+
|_CreationDate|_Id|_LinkTypeId|_PostId|_RelatedPostId|
+-----+-----+-----+-----+-----+
|2014-01-21 21:04:25.23|25|3|29|25|
|2014-01-21 21:42:09.103|89|1|83|50|
|2014-01-21 21:50:41.313|95|1|86|2|
|2014-01-21 22:07:35.783|101|3|47|99|
|2014-01-21 22:13:51.38|102|1|74|3|
+-----+-----+-----+-----+-----+

```

only showing top 5 rows

## 2.2.6 Plik Post History

```

history_schema = StructType([
    StructField("_Comment", StringType()),
    StructField("_ContentLicense", StringType()),
    StructField("_CreationDate", TimestampType()),
    StructField("_Id", IntegerType()),
    StructField("_PostHistoryTypeId", IntegerType()),
    StructField("_PostId", IntegerType()),
    StructField("_RevisionGUID", StringType()),
    StructField("_Text", StringType()),
    StructField("_UserDisplayName", StringType()),
    StructField("_UserId", IntegerType()),
])

```

```

-RECORD 0-----
 _Comment          | null
 _ContentLicense   | CC BY-SA 3.0
 _CreationDate     | 2014-01-21 20:26:05.383
 _Id               | 1
 _PostHistoryTypeId| 2
 _PostId          | 1
 _RevisionGUID     | a17002a0-00b0-417b-a404-0d8864bbbca5
 _Text            | I was offered a beer the other day that was reportedly ma...

```

```

_UserDisplayName | null
_UserId         | 7
only showing top 1 row

```

## 2.2.7 Plik Badges

```

badges_schema = StructType([
    StructField("_Class", IntegerType()),
    StructField("_Date", TimestampType()),
    StructField("_Id", IntegerType()),
    StructField("_Name", StringType()),
    StructField("_TagBased", BooleanType()),
    StructField("_UserId", IntegerType()),
])

```

```

+-----+-----+-----+-----+-----+-----+
|_Class|_Date                |_Id|_Name                |_TagBased|_UserId|
+-----+-----+-----+-----+-----+-----+
|3      |2014-01-21 20:52:16.97|1  |Autobiographer|false    |1      |
|3      |2014-01-21 20:52:16.97|2  |Autobiographer|false    |2      |
|3      |2014-01-21 20:52:16.97|3  |Autobiographer|false    |6      |
|3      |2014-01-21 20:52:16.97|4  |Autobiographer|false    |7      |
|3      |2014-01-21 20:52:16.97|5  |Autobiographer|false    |9      |
+-----+-----+-----+-----+-----+-----+
only showing top 5 rows

```

## 2.3 Czyszczenie kolumn tekstowych

Pliki `Users`, `History` oraz `Posts` zawierają kolumny tekstowe z danymi wpisywanymi przez użytkowników oraz często zawierające znaki specjalne czy tagi html. W związku z tym kolumny `_AboutMe` (plik `Users`), `_Text` (plik `History`) oraz `_Body` (plik `Posts`) zostały poddane procesowi oczyszczania.

W tym celu utworzono funkcję UDF o nazwie `tags_remove()` Sekcja [B.1](#), która odpowiada za usunięcie tagów html.

Dodatkowo znaki `\n`, `\t`, `\r` oraz podwójne spacje zastąpiono pojedynczymi znakami spacji a także usunięto znaki spacji z początków i końców wartości tekstowych.

Poniżej zaprezentowano przykłady kolumn nieoczyszczonych oraz po ich oczyszczeniu (zawierające końcówkę `_clean`):

- Dla pliku `Users`:

```

-RECORD 0-----
_AboutMe          | <p>Hi, I'm not really a person.</p>\n\n<p>I'm a backgroun...
_AboutMe_clean    | Hi, I'm not really a person. I'm a background process tha...
-RECORD 1-----
_AboutMe          | <p>Dev #2 who helped create Stack Overflow currently work...
_AboutMe_clean    | Dev #2 who helped create Stack Overflow currently working...

```



```

-RECORD 2-----
  _AboutMe      | <p>Former Stack Exchange employee</p>\n
  _AboutMe_clean | Former Stack Exchange employee
-RECORD 3-----
  _AboutMe      | \n<p>Developer at Stack Overflow focusing on public Q&amp;...
  _AboutMe_clean | Developer at Stack Overflow focusing on public Q&A. Russi...
-RECORD 4-----
  _AboutMe      | <p><strong>BY DAY:</strong> I execute projects on both mo...
  _AboutMe_clean | BY DAY: I execute projects on both mobile and on the web ...
only showing top 5 rows

```

[Stage 7:> (0 + 1) / 1]

- Dla pliku History:

```

-RECORD 0-----
  _Text         | I was offered a beer the other day that was reportedly ma...
  _Text_clean   | I was offered a beer the other day that was reportedly ma...
-RECORD 1-----
  _Text         | What is a citra hop, and how does it differ from other hops?
  _Text_clean   | What is a citra hop, and how does it differ from other hops?
-RECORD 2-----
  _Text         | <hops>
  _Text_clean   |
-RECORD 3-----
  _Text         | As far as we know, when did humans first brew beer, and w...
  _Text_clean   | As far as we know, when did humans first brew beer, and w...
-RECORD 4-----
  _Text         | When was the first beer ever brewed?
  _Text_clean   | When was the first beer ever brewed?
only showing top 5 rows

```

```

/config/workspace/env/lib/python3.10/site-packages/bs4/__init__.py:435: MarkupResemblesLocatorWarning:
  warnings.warn(

```

- Dla pliku Posts:

```

-RECORD 0-----
  _Body         | <p>I was offered a beer the other day that was reportedly...
  _Body_clean   | I was offered a beer the other day that was reportedly ma...
-RECORD 1-----
  _Body         | <p>As far as we know, when did humans first brew beer, an...
  _Body_clean   | As far as we know, when did humans first brew beer, and w...
-RECORD 2-----
  _Body         | <p>How is low/no alcohol beer made? I'm assuming that the...
  _Body_clean   | How is low/no alcohol beer made? I'm assuming that the be...
-RECORD 3-----
  _Body         | <p>Citra is a registered trademark since 2007. Citra Bran...
  _Body_clean   | Citra is a registered trademark since 2007. Citra Brand h...

```


```
-RECORD 4-----  
_Body          | <p>In general, what's the best way to work out the temper...  
_Body_clean    | In general, what's the best way to work out the temperatu...  
only showing top 5 rows
```

Tak przygotowane dane, w celu optymalizacji miejsca zajmowanego w koszyku S3, oraz w celu przyspieszenia procesu wczytywania danych zapisano w formacie **parquet**. Zaskutkowało to redukcją zajmowanego miejsca w koszyku o około 50%.

## 3 Analiza danych


### 3.1 Analiza aktywności użytkowników na forum

Jako pierwsze postanowiono zbadać czy forum jest aktywne. W tym celu liczbę postów zagregowano w miesięczne interwały i zliczono ich ilość. Pierwsza wiadomość pojawiła się na forum 2014-01-21 natomiast ostatnia 2022-06-05. Na przestrzeni tych ~8,5 roku pojawiło się 3769 postów. Z Rysunek 3.1 widać, że zainteresowanie forum spadało w czasie. W rekordowych pierwszych 2 miesiącach umieszczano ich odpowiednio 413 oraz 190, natomiast pod koniec badanego okresu wartości często nie przekraczały 10.



Rysunek 3.1: Liczba postów w czasie z podziałem na pytania i odpowiedzi. Lewy panel wskazuje surowe wartości liczby postów, prawy wartości logarytmiczne o podstawie 10. Zamieszczono również linię trendu obliczoną przy użyciu algorytmu LOESS (ang. *Local Polynomial Regression Fitting*)

Stosunek ilości odpowiedzi do zadawanych pytań (ratio) rósł do roku 2021, w którym to zaczęto odnotowywać spadek. Na wzrost ratio miała wpływ zmniejszająca się ilość zadawanych pytań (maleje próba badana) co zostało przedstawione na Rysunek 3.2. Patrząc na wartości średnie tylko co drugie pytanie uzyskiwało odpowiedź (ratio  $0.48 \pm 0.22$ ). Ogólne statystyki stosunku pytań do odpowiedzi w czasie zostały przedstawione w Tabela 3.1.



Rysunek 3.2: Stosunek ilości odpowiedzi na zadane pytania w czasie, uwzględniając ilość zadanych pytań

Tabela 3.1: Statystyki stosunku ilości odpowiedzi na pytania. Bez uwzględnienia czy było ono zaakceptowane czy też nie.

	średnia	odchylenie standardowe	min	max	mediana
0	0.476316	0.219824	0.0	1.5	0.444444

Tabela 3.2: Statystyki ocen odpowiedzi zaakceptowanych w stosunku do pozostałych

	is_accepted	średnia	odchylenie standardowe	min	max	mediana
0	None	2.755169	3.181837	-5	30	2
1	True	6.395044	5.915949	0	46	5
2	False	2.584169	2.735329	-4	26	2

Tabela 3.3: Statystyki czasu od pojawienia się pytania do zaakceptowanej odpowiedzi w minutach

	średnia	odchylenie standardowe	min	max	mediana
0	25244.943571	12338.63251	0.0	1506239.05	753.25

## 3.2 Dynamika oraz statystyki udzielanych odpowiedzi

Twórcy pytań na forum mają możliwość wybrania odpowiedzi, która jest najtrafniejsza i zawiera poprawną odpowiedź. Te odpowiedzi nazywane są zaakceptowanymi odpowiedziami. Zbadano jak często najwyżej oceniona odpowiedź nie była zaakceptowaną odpowiedzią.

Okazało się, że w przypadku pytań, które posiadały jakąkolwiek odpowiedź, około 12.7% (646) przypadków najlepiej ocenianych odpowiedzi nie było tą, która została zaakceptowana przez autora.

Następnie porównano oceny odpowiedzi zaakceptowanych z pozostałymi odpowiedziami a statystyki przedstawiono w Tabeli 3.2 oraz Rysunek 3.3.

Pośród odpowiedzi na zadawane pytania wyróżniono 3 kategorie:

1. odpowiedź zaakceptowana (`is_accepted=True`)
2. odpowiedź niezaakceptowana (`is_accepted=False`)
3. odpowiedź niezaakceptowana ale równocześnie brak jest zaakceptowanej odpowiedzi na to pytanie (`is_accepted=None`)


Z analizy wynika, iż zaakceptowane odpowiedzi mają średnio wyższe oceny użytkowników (6,39) niż pozostałe oceny (2.75 - `is_accepted=None`; 2.58 - `is_accepted=False`), co było oczekiwanym wynikiem.

Następnie zbadano jak szybko od pojawienia się pytania, pojawia się zaakceptowana odpowiedź. Dla wszystkich pytań na tym forum jest to średnio 25244 minuty, ale wartość środkowa (753) sugeruje, że średnia może być zaburzona. W celu obliczenia średniej nie zaburzonej tak dużymi wartościami odstającymi odrzucono wartości znajdujące powyżej 6 odchylen standardowych od średniej (75894 minut). Tym razem uzyskano wartość 3988 minut (~66,5 godziny), przy wartości środkowej 628 (~10,5 godziny).


Rozkłady wartości przedstawiono na Rysunek 3.4 oraz w Tabeli 3.3 dla całego zbioru danych oraz Tabela 3.4 po odrzuceniu wartości odstających.

Tabela 3.4: Statystyki ocen odpowiedzi zaakceptowanych w stosunku do pozostałych po odrzuceniu wartości odstających ( $> 6 \cdot SD$ )

	średnia	odchylenie standardowe	min	max	mediana
0	3988.821096	9775.983836	0.0	73465.9	628.72




Rysunek 3.3: Rozkład ocen pytań zaakceptowanych w porównaniu do pozostałych



Rysunek 3.4: Rozkład czasu od pojawienia się pytania do zaakceptowanej odpowiedzi w minutach

### 3.3 Retencja użytkowników

W całej historii forum zarejestrowanych zostało 8948 użytkowników, z czego jedno konto jest kontem bota. Miarą retencji użytkownika na forum określono czas od utworzenia konta to ostatniej zamieszczonej wiadomości. Wśród 50 najdłużej aktywnych kont zidentyfikowano konto z wynikiem aż 3052 dni a konto z ostatnim indeksem w tej grupie miało wynik 2128 dni. Jednakże patrząc na całą populację, wartość środkowa wyniosła 11, a 50% wartości mieści się pomiędzy 0 a 594 dniami. Użytkownicy z wartością 0, są to najprawdopodobniej użytkownicy, którzy zadali jedyne pytanie na forum w dniu założenia konta (410 użytkowników). Czas na forum najdłużej aktywnych użytkowników został zwizualizowany na Rysunek 3.5. Dodatkowo okazało się, że 7691 (86%) kont było biernymi użytkownikami forum i nigdy nie dodało żadnego posta.



Rysunek 3.5: Czas na forum 50 najdłużej aktywnych kont

Tabela 3.5: Statystyki długości postów (liczba znaków)

	średnia	odchylenie standardowe	max	min	mediana
0	415.863676	330.836043	3133	30	331

Tabela 3.6: Statystyki ocen użytkowników

	średnia	odchylenie standardowe	max	min	mediana
0	6.278804	5.876114	68	-7	5

### 3.4 Statystyki najwyżej oraz najniżej ocenianych pytań

Zbadano statystyki zadawanych pytań. Użytkownicy forum mogą oceniać pojawiające się tam pytania czego miarą jest wartość `score`. Sprawdzono, czy długość zadanego pytania ma wpływ na jego ocenę.

Średnia długość pytania wyniosła 415 znaków (+/- 330) a wartość środkowa 331 znaków. Najdłuższe pytanie posiadało 3133 znaki a najkrótsze jedynie 30. Statystyki przedstawiono w Tabeli 3.5.

Średnio pytanie było oceniane na wartość 6.28 (+/-5.88) a wartość środkowa wyniosła 5. Najlepiej oceniane pytanie miało ocenę 67 a najgorzej -7. Statystyki zestawiono w Tabeli 3.6.

Zależność pomiędzy wartością `score` a długością wiadomości przedstawiono na Rysunek 3.6. Ze względu na obecność dużej ilości wartości odstających obie wartości przedstawiono również w skali logarymicznej.

Nie wykryto korelacji pomiędzy tymi dwoma zmiennymi. Współczynnik korelacji wyniósł -0.048 oraz -0.018 dla wartości zlogarytmowanych.

Postanowiono dodatkowo zbadać dwie podgrupy danych dla pytań najlepiej oraz najgorzej ocenianych. Wyodrębniono po 100 pytań z każdej z grup. Wyniki dla tych grup przedstawiono na Rysunek 3.6 (dolny panel) oraz w Tabeli 3.7 i Tabeli 3.8.

W podgrupie najlepiej ocenianych pytań średnia ocena wyniosła 20.6 +/- 8.5 a w podgrupie najgorzej ocenianych 0.4 +/- 1.2. Rozdzielność tych statystyk dla tych grup była oczekiwanym wynikiem.

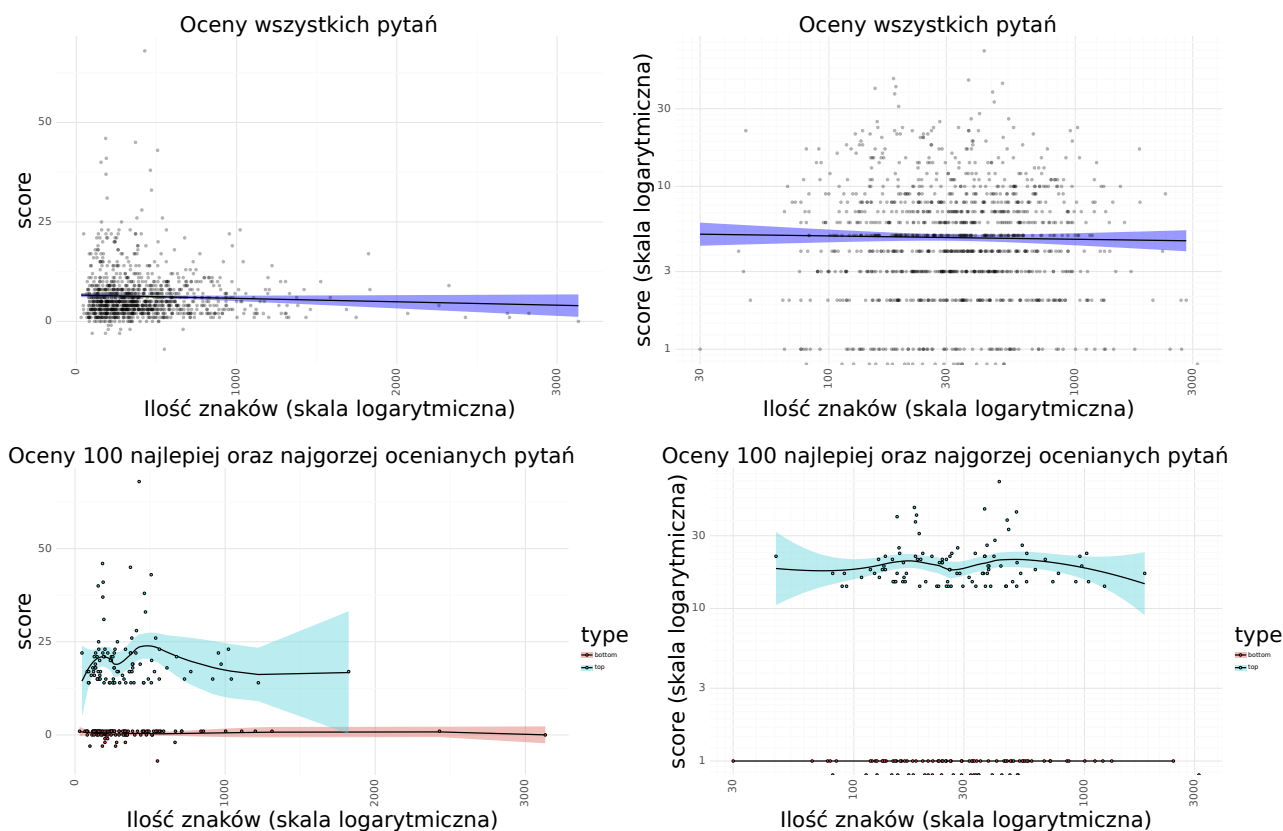
Statystyki długości pytań nie odbiegają od siebie w znaczący sposób (średnie 349 +/- 275 najlepiej oceniane oraz 389 +/- 424 najgorzej oceniane) sugerując iż to długość pytania nie ma znaczącego wpływu na jego ocenę.

Zauważono również że najlepiej oceniane pytania są również częściej oglądane i mają więcej odpowiedzi niż pytania najgorzej oceniane (Rysunek 3.7). Najlepiej oceniane pytania mają średnio 4 odpowiedzi podczas gdy najgorzej jedynie 1 (Tabela 3.9) oraz odpowiednio średnio 26289 i 475 wyświetleń (Tabela 3.10)

Tabela 3.7: Statystyki długości postów z podziałem na podgrupy najlepszych (type=top) i najgorszych pytań (type=bottom)

	type	średnia	odchylenie standardowe	max	min	mediana
0	top	349.08	275.088587	1823	46	261
1	bottom	389.26	424.654836	3133	30	270





Rysunek 3.6: Oceny pytań (score) na forum w zależności od ilości znaków zawartych w pytaniu

Tabela 3.8: Statystyki ocen użytkowników z podziałem na podgrupy najlepszych (type=top) i najgorszych pytań (type=bottom)


	type	średnia	odchylenie standardowe	max	min	mediana
0	top	20.6	8.551685	68	14	18
1	bottom	0.4	1.206045	1	-7	1

Tabela 3.9: Statystyki ilości odpowiedzi na pytania z podziałem na podgrupy najlepszych (type=top) i najgorszych (type=bottom) pytań

	type	średnia	odchylenie standardowe	max	min	mediana
0	top	3.96	2.581676	17	1	3
1	bottom	1.28	0.964836	4	0	1

Tabela 3.10: Statystyki ilości wyświetleń pytań z podziałem na podgrupy najlepszych (type=top) i najgorszych (type=bottom) pytań


	type	średnia	odchylenie standardowe	max	min	mediana
0	top	26047.65	76276.200191	648941	175	4715
1	bottom	495.56	1220.756292	9124	3	141



Rysunek 3.7: Liczba odpowiedzi oraz oceny najlepiej (type=top) oraz najgorzej (type=bottom) ocenianych pytań w zależności od liczby ich wyświetleń



pierwszej wiadomości na forum. W danych zauważono również, że częstość używania znaczników jest skokowa. Może to być związane z ogólną małą ilością postów zamieszczanych na forum. Wyjątek stanowią najpopularniejsze znaczniki, takie jak **taste** czy **health**, których częstość występowania jest bardziej regularna.



Rysunek 3.9: Liczba postów w czasie dla każdego z najczęściej wyświetlanych znaczników. Wartości zagregowane na poziomie miesięcy. Górny panel przedstawia wartości miesięczne, dolny natomiast miesięczną sumę kumulatywną.

Tabela 3.12: Przykładowe rekordy danych wizualizujące proces przetwarzania tekstu. Kolejność chronologiczna kolumn title -> words\_token -> words\_no\_stop -> words\_stem

	0
title	What is a citra hop, and how does it differ from other hops?
words_token	[what, is, citra, hop, and, how, does, it, differ, from, other, hops]
words_no_stop	[citra, hop, differ, hops]
words_stem	[citra, hop, differ, hop]

### 3.6 Analiza tytułów postów

Dodatkową metodą, oprócz analizy znaczników, którą można wykorzystać w celu zbadania tematów poruszanych na forum może być analiza najczęściej pojawiających się słów. Można do tego wykorzystać treść tytułów wiadomości jak i ich główną treść. W niniejszej pracy skupiono się na analizie treści tytułów wiadomości, jako że bardzo często zawierają one dużo słów kluczowych.

Tytuły wiadomości są nieustrukturyzowanymi ciągami znaków, z tego powodu do ich analizy wykorzystano powszechnie używane narzędzia stosowane przy analizach NLP (ang. *Natural Language Processing*). Proces zastosowanej tutaj analizy tekstu składał się z 4 kroków:

1. Wyodrębnienia tokenów
2. Usunięcia tokenów o długości znaku 1
3. Usunięcia tokenów nie niosących informacji o treści (ang. *stop words*)
4. Ujednolicenia różnych form danego wyrazu poprzez zabieg stemming'u (ang. *stemming*), mającego na celu ucinanie końcówek wyrazów (tokenów) i pozostawieniu jedynie jego wartości bazowej.

Przykładowa tabela wizualizująca tokeny surowe w porównaniu do tokenów po odfiltrowaniu słów typu **stop words** oraz tokenów krótszych niż 1 zaprezentowano na Tabeli 3.12

Dzięki zabiegowi stemmingu otrzymywany jest bardziej jednorodny zestaw danych. Liczba unikalnych tokenów została zredukowana z 2055 do 1680.

Następnie zliczono, które tokeny pojawiają się w największej ilości tytułów i zaprezentowano w Tabeli 3.13. Najczęściej używanymi tokenami były tokeny **beer** (476), **wine** (152) oraz **drink** (105). Wyniki pozostają w zgodzie z wnioskami uzyskanymi poprzez analizę znaczników.

Tabela 3.13: Zliczenia tokenów słów najczęściej pojawiających się w tytułach postów (15 najliczniejszych)

	words	count
0	beer	476
1	wine	147
2	drink	104
3	alcohol	88
4	differ	72
5	bottl	68
6	use	50
7	tast	47
8	brew	43
9	make	41
10	good	33
11	cocktail	29
12	age	27
13	ale	26
14	recommend	26

### **Cześć III**

## **WNIOSKI I ZAKOŃCZENIE**

## Budowa infrastruktury

W niniejszej pracy przygotowano podstawowe środowisko pracy do analizy zbiorów danych. Jako środowisko przechowywania danych wykorzystano serwis **S3** który pozwala na przechowywanie wiele typów oraz formatów danych i jest łatwo skalowalny oraz posiada opcje optymalizacji oraz archiwizacji danych. Do zapisania danych w serwisie **S3** wykorzystano usługę **Cloud9**, jednak równie dobrze użytkownik może wykonać opisane w tej pracy kroki na każdej maszynie (również poza chmurą **AWS**), wystarczy tylko wygenerowanie i użycie odpowiednich kluczy dostępu. **Cloud9** wydaje się jednak prostszym rozwiązaniem, gdyż zawiera już zainstalowany program **AWS CLI**, który może być wykorzystany do zapisania danych w serwisie **S3**.

Część analityczną zaprojektowano w sposób aby jak najbardziej uprościć konfigurację by móc skupić się na przeprowadzeniu analizy danych. Wykorzystano popularne narzędzie **Apache Spark** (głównie moduł **SQL**) oraz serwis **AWS EMR** ze środowiskiem graficznym **Jupyter Hub**, bardzo popularnym wśród programistów/analityków w języku **python**. Dodatkowo zadbane o to żeby efekty pracy (notebooki) oraz logi były automatycznie zapisywane w osobnych koszykach w serwisie **S3**.

W przypadku chęci usprawnienia i optymalizacji rozwiązania możliwa jest dodatkowa konfiguracja obecnej infrastruktury. Jedym z możliwych usprawnień jest redukcja zajmowanego miejsca w serwisie **S3**. Koszyk danych **raw-data-beer-and-wine** może posiadać automatyczne usuwanie danych lub archiwizację danych w serwisie **S3 Glacier**, jako że dane w formacie **xml** po ekstrakcji i zapisaniu ich w formacie **parquet** są danymi nadmiarowymi.

Potencjalny schemat tego rozwiązania mógłby składać się z następujących kroków:

1. Wykonywanie kodu z sekcji Sekcja 1.1, mogłoby zostać zautomatyzowane poprzez cykliczne uruchamianie skryptu o danej godzinie np. przy pomocy serwisu **AWS Lambda** bądź **AWS Batch**
2. Po wykonaniu ekstrakcji uruchamiany byłby kod do wstępnego przetwarzania danych zapisujący dane w formacie **parquet** opisany w Sekcja 1.2 oraz w szczegółach w Rozdział 2
3. Dane z koszyka **raw-data-beer-and-wine** byłyby usuwane godzinę po zakończeniu kroku numer 2.

W przypadku prezentowanego w tej pracy przykładu optymalizacja przechowywania danych nie jest etapem kluczowym, ze względu na stosunkowo mały rozmiar danych, lecz będzie to miało istotne znaczenie w kosztach analizy, gdy rozmiar danych będzie zwiększony.

Kolejnym usprawnieniem w celu usprawnienia tworzenia niezbędnej infrastruktury jest zapisanie jej w postaci projektu typu **Infrastructure as a Code**. Pozwoliłoby to na śledzenie zmian w projekcie przy pomocy kontroli wersji a także dodawanie kolejnych komponentów wspomnianych wyżej lub usuwanie komponentów w sposób programatyczny. Można w tym celu wykorzystać programy **AWS CDK**[5], **Terraform**[4] lub bezpośrednio **AWS CloudFormation**[6].

## Analiza danych

W części analitycznej pracy zbadano charakterystykę jednego z forów internetowych. W Sekcja 3.1, Sekcja 3.2 oraz Sekcja 3.3 dokonano wstępnych analiz zachowań użytkowników na forum, takich jak częstotliwość zadawania pytań, uzyskiwania odpowiedzi czy retencji na forum. Wyniki mogą posłużyć za wstęp do głębszych analiz przez właścicieli forum, w celu poszukiwania metod uatrakcyjnienia dostarczanego produktu, jako że forum z czasem znacząco traci na popularności.



W kolejnych sekcjach (Sekcja 3.4, Sekcja 3.5, Sekcja 3.6) dokonano analizy treści oraz jakości zamieszczanych na forum informacji. Sekcja 3.4 zidentyfikowała najlepiej oraz najgorzej oceniane pytania. Ich dokładniejsza analiza może posłużyć do zbadania treści tych wiadomości w celu stworzenia instrukcji dla nowych użytkowników o tym, co powinno znaleźć się w treści pytania, aby zwiększyć szanse na uzyskanie odpowiedzi. W Sekcja 3.5 oraz Sekcja 3.6 dokonano wstępnej analizy tematyki zadawanych pytań. Podejście opierało się na wyszukiwaniu najpopularniejszych słów kluczowych wśród znaczników (tagów) oraz tytułów postów. W celu pogłębienia tej analizy można spróbować wykorzystać technikę **tf-idf** [15] w celu identyfikacji charakterystycznych słów, biorąc pod uwagę ich występowanie pomiędzy postami. Dodatkowo możliwe jest grupowanie podobnych do siebie postów przy pomocy algorytmu **TextRank** [11]. Algorytm ten można wykorzystać w celu oferowania podpowiedzi użytkownikom, którzy zadają pytanie na forum będące duplikatem już istniejącego.

# A Budowanie infrastruktury chmurowej

## A.1 Polecenie AWS CLI dla usługi EMR

```
aws emr create-cluster --name="MyEMRCluster" \
  --release-label emr-6.8.0 \
  --applications Name=JupyterHub Name=Hadoop Name=Spark \
  --log-uri s3://emr-logs-beer-and-wine/MyJupyterClusterLogs \
  --use-default-roles \
  --instance-groups InstanceGroupType=MASTER,InstanceCount=1,InstanceType=m4.xlarge, \
    BidPrice=OnDemandPrice \
    InstanceGroupType=CORE,InstanceCount=2,InstanceType=m4.xlarge,BidPrice=OnDemandPrice \
  --efs-root-volume-size 32 \
  --configurations file://emr-configurations.json \
  --bootstrap-actions \
    Path=s3://misc-beer-and-wine/install_python_libraries.sh,Name=InstallJupyterLibs
```

## A.2 Plik install-my-jupyter-libraries.sh

Odpowiada za zainstalowanie dodatkowych bibliotek pythonowych na węzłach typu *master* oraz *worker*. Wykorzystany w parametrze `--bootstrap-actions` Sekcja [A.1](#)

```
#!/bin/bash

sudo python3 -m pip install matplotlib plotnine wordcloud bs4 html nltk pandas \
  && patchworklib boto3 pyspark jupyter-client scikit-misc
```

## A.3 Plik emr-configurations.json

Odpowiada za automatycznie zapisywanie notebooków w serwisie S3. Wykorzystany w parametrze `--configurations` Sekcja [A.1](#).

```
[
  {
    "Classification": "jupyter-s3-conf",
    "Properties": {
      "s3.persistance.enabled": "true",
      "s3.persistance.bucket": "emr-jupyter-notebooks-zjasdu123"
    }
  }
]
```

## A.4 Polecenie AWS CLI dla usługi S3

Koszyki S3 zostały utworzone przy pomocy poniższego polecenia:

```
aws s3api create-bucket --acl private --bucket <nazwa koszka>
```

## B Definicje funkcji

### B.1 tags\_remove()

```
from pyspark.sql.functions import udf
from bs4 import BeautifulSoup
from html import unescape

def tags_remove(s):
    if s is not None:
        soup = BeautifulSoup(unescape(s), 'lxml')
        return soup.text
    else:
        return None
udf_tags_remove = udf(lambda m: tags_remove(m))
```

### B.2 regexp\_extract\_all()

Źródło: <https://gist.github.com/dannymeijer/be3534470b205280e52dbbcbb19a9670>

```
from pyspark.sql import DataFrame
from pyspark.sql import functions as f

def regexp_extract_all(
    df: DataFrame,
    regex: str,
    no_of_extracts: int,
    input_column_name: str,
    output_column_name: str = "output",
    empty_array_replace: bool = True,
):
    """PySpark implementation for extracting all matches of a reg_exp_extract

    Background
    -----
    The regular implementation of regexp_extract (as part of pyspark.sql.functions module)
    is not capable of returning more than 1 match on a regexp string at a time. This
    function can be used to circumvent this limitation.

    How it works
    -----
    You can specify a `no_of_extracts` which will essentially run the regexp_extract
    function that number of times on the `input_column` of the `df` (`DataFrame`).
    In between extracts, a set of interim columns are created where every
```

intermediate match is stored. A distinct array is created from these matches, after which the interim columns are dropped. The resulting array is stored in the defined `output\_column`. Empty strings/values in the resulting array can optionally be dropped or kept depending on how `empty\_array\_replace` is set (default is True).

#### Usage example

-----

In the below example, we are extracting all email-addresses from a body of text. The returned DataFrame will have a new ArrayType column added named `email\_addresses`

```
> # Assuming `df` is a valid DataFrame containing a column named `text`
> email_regex = r"[\w.-]+@[ \w.-]+\.[a-zA-Z]{1,}"
> df = regexp_extract_all(df, email_regex, 6, "text", "email_addresses", True)
```

#### Parameters

-----

df: DataFrame

Input DataFrame

regex: str

Regex string to extract from input DataFrame

no\_of\_extracts: int

Max number of occurrences to extract

input\_column\_name: str

Name of the input column

output\_column\_name: str

Name of the output column (default: output)

empty\_array\_replace: bool

If set to True, will replace empty arrays with null values (default: True)

"""

```
repeats = range(0, no_of_extracts)
```

# A set of interim columns are created that will be dropped afterwards

```
match_columns = [f"__{r}__" for r in repeats]
```

# Apply regexp\_extract an r number of times

```
for r in repeats:
```

```
    df = df.withColumn(
```

```
        match_columns[r],
```

```
        f.regexp_extract(
```

```
            f.col(input_column_name),
```

```
            # the input regex string is amended with ".*?"
```

```
            # and repeated an r number of times
```

```
            # r needs to be +1 as matching groups are 1-indexed
```

```
            "".join([f"{regex}.*?" for i in range(0, r + 1)]),
```

```
            r + 1,
```

```
        ),
```

```
    )
```

# Create a distinct array with all empty strings removed

```

df = df.withColumn(
    output_column_name,
    f.array_remove(f.array_distinct(f.array(match_columns)), ""),
)

# Replace empty string with None if empty_array_replace was set
if empty_array_replace:
    df = df.withColumn(
        output_column_name,
        f.when(f.size(output_column_name) == 0, f.lit(None)).otherwise(
            f.col(output_column_name)
        ),
    )

# Drop interim columns
for c in match_columns:
    df = df.drop(c)

return df

```

## **C Repozytorium kodu wykorzystanego w pracy**

<https://github.com/michkam89/big-data-pw-project>

# Bibliografia

- [1] *Amazon EC2: Secure and resizable compute capacity for virtually any workload*. URL: <https://aws.amazon.com/ec2/>.
- [2] *Amazon Rekognition: Automate your image and video analysis with machine learning*. URL: <https://aws.amazon.com/rekognition/>.
- [3] *Apache Hadoop*. URL: <https://hadoop.apache.org/>.
- [4] *Automate Infrastructure on Any Cloud*. URL: <https://www.terraform.io/>.
- [5] *AWS CDK: Define your cloud application resources using familiar programming languages*. URL: <https://aws.amazon.com/cdk/>.
- [6] *AWS CloudFormation: Speed up cloud provisioning with infrastructure as code*. URL: <https://aws.amazon.com/cloudformation/>.
- [7] *AWS Lambda: Run code without thinking about servers or clusters*. URL: <https://aws.amazon.com/lambda/>.
- [8] Kevin Bartley. “Data Statistics - how much data is there in the world?” W: *Rivery* (list. 2022). URL: <https://rivery.io/blog/big-data-statistics-how-much-data-is-there-in-the-world/>.
- [9] Jeffrey Dean i Sanjay Ghemawat. “System and method for efficient large-scale data processing”. Sty. 2010.
- [10] James Maguire. *Top 16 cloud service providers and companies in 2023*. Sty. 2023. URL: <https://www.datamation.com/cloud/cloud-service-providers/>.
- [11] Rada Mihalcea i Paul Tarau. “TextRank: Bringing Order into Texts”. W: (). URL: <https://web.eecs.umich.edu/~mihalcea/papers/mihalcea.emnlp04.pdf>.
- [12] Álvaro Navarro. *Understanding the data partitioning technique*. Lut. 2017. URL: <https://www.datio.com/iaas/understanding-the-data-partitioning-technique/>.
- [13] *Stack Exchange*. URL: <https://stackexchange.com/>.
- [14] *Stack Exchange - Beer, Wine and Spirits*. URL: <https://data.stackexchange.com/beer/queries>.
- [15] *TFIDF*. Paź. 2020. URL: <https://pl.wikipedia.org/wiki/TFIDF>.
- [16] *Why and how companies need to take advantage of (BIG) data science*. Wrz. 2021. URL: <https://exafutures.com/en/why-how-companies-need-to-take-advantage-of-big-data-science>.
- [17] Matei Zaharia i in. “Resilient Distributed Datasets: A Fault-Tolerant Abstraction for In-Memory Cluster Computing”. W: (2012). URL: [http://people.csail.mit.edu/matei/papers/2012/nsdi\\_spark.pdf](http://people.csail.mit.edu/matei/papers/2012/nsdi_spark.pdf).
- [18] Matei Zaharia i in. “Spark: Cluster Computing with Working Sets”. W: (2010). URL: [http://people.csail.mit.edu/matei/papers/2010/hotcloud\\_spark.pdf](http://people.csail.mit.edu/matei/papers/2010/hotcloud_spark.pdf).